BÁO CÁO NGHIÊN CỨU ĐỀ TÀI: HCMC-HYDROCAST

Môn học: SE363 – Phát triển ứng dụng trên nền tảng dữ liệu lớn
Đơn vị: Khoa Kỹ thuật Phần mềm – Trường Đại học Công nghệ Thông tin (UIT - VNU-HCM)

Mục lục

1 Tên đề tài **1**

2 Tính cấp thiết của đề tài **1**

3 Đóng góp của đề tài **2**

4 Các Modalities và Nguồn dữ liệu khí tượng - thủy văn TP.HCM **2**

5 Kiến trúc hệ thống tổng thể (System Architecture) **4**

---

1 Tên đề tài

- **Tên tiếng Việt: Hệ thống Xử lý Dữ liệu Lớn Dạng Luồng Hỗ trợ Giám sát và Dự báo Mưa Ngắn Hạn Đô thị Dựa trên Mạng lưới Trạm Quan trắc Mặt đất tại TP. Hồ Chí Minh**
- **Tên tiếng Anh: HCMC-HydroCast: A Real-Time Big Data Streaming Pipeline for Gauge-Calibrated Urban Rain Nowcasting in Ho Chi Minh City**
- **Tên ngắn / Định danh:** `HCMC-HydroCast`

2 Tính cấp thiết của đề tài

- **Thực trạng đô thị:** Hơn 70 triệu xe máy tại Việt Nam và hàng trăm ngàn người di chuyển liên tục ngoài trời. Tại TP.HCM, ngập úng đô thị là **bài toán kép: Mưa dông nhiệt cực đoan ($>$ 50 mm/h trút trong 15–30 phút) kết hợp Triều cường dâng cao ($>$ 1.5 m)** làm vô hiệu hóa hệ thống cống thoát ra sông Sài Gòn, gây ngập sâu tức thì và làm hàng loạt xe chết máy.
- **Dữ liệu Radar Doppler không công khai:** Các mô hình dự báo cực ngắn hàng đầu thế giới (NowcastNet, MetNet-3) dựa trên ảnh Radar Doppler liên tục (1 km / 5 phút). Tại Việt Nam, mạng lưới Radar quốc gia không cung cấp API công khai theo thời gian thực cho cộng đồng nghiên cứu. Đề tài tiếp cận bài toán theo góc độ **Multimodal Learning under Missing Modality** (Học máy đa phương thức trong điều kiện khuyết modality radar), đồng hóa các nguồn dữ liệu thay thế để bù đắp tín hiệu quan sát.
- **Điểm mù của mô hình toàn cầu:** Các mô hình số trị toàn cầu (ECMWF, GFS) có độ phân giải thô (9–25 km) và chu kỳ chạy cách nhau 6 giờ, gộp toàn bộ trung tâm TP.HCM vào chung 1 ô lưới, hoàn toàn bỏ lọt các ổ mây dông đối lưu quy mô nhỏ 1–2 km.

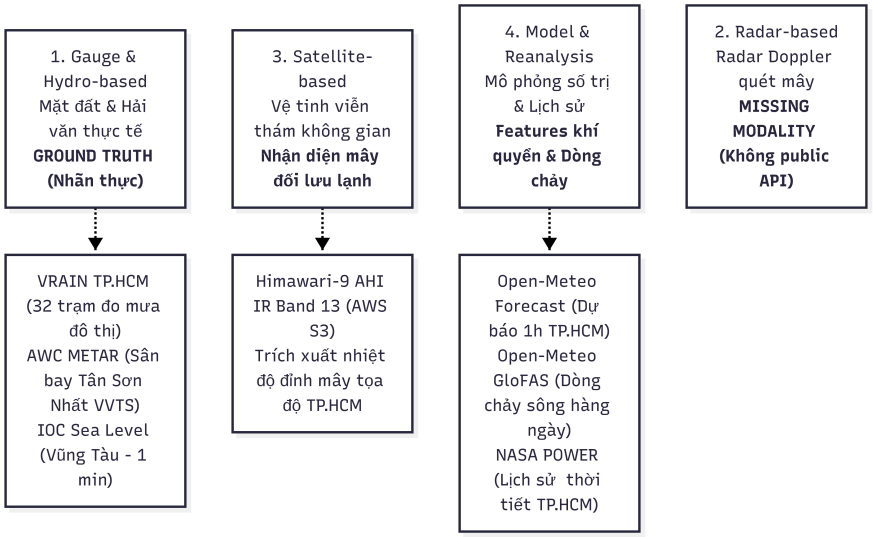
- **Hạn chế của các sản phẩm hiện tại:** Apple Weather không hỗ trợ tính năng *"Dự báo theo giờ"* tại Việt Nam; AccuWeather chỉ ngoại suy ảnh vệ tinh thô. Người dùng và đội xe cần một giải pháp dựa trên dữ liệu trạm đo thực địa: *"Các trạm xung quanh tôi vừa đo được bao nhiêu mm nước mưa, triều cường cửa sông đang dâng cao ra sao, và mô hình quốc tế có đang báo ảo hay không?"*.

3 Đóng góp của đề tài

1. **Pipeline Streaming Đa Nguồn:** Xây dựng luồng streaming với **Kafka (decoupled topics) + Spark Structured Streaming + TimescaleDB**, đồng hóa dữ liệu dị thể từ 32 trạm đo mưa đô thị TP.HCM (VRAIN), trạm khí tượng sân bay Tân Sơn Nhất (METAR VVTS), trạm hải văn đo triều cường cửa biển (IOC Sea Level Vũng Tàu), và dòng chảy sông thượng nguồn lưu vực Sài Gòn - Đồng Nai (Open-Meteo GloFAS).
2. **Bộ Dữ liệu Chuẩn Đồ thị Đa Phương thức (`HCMC-HydroMet-Graph`):** Đóng gói bộ dữ liệu kết hợp trạm đo mặt đất TP.HCM (VRAIN), trạm sân bay (METAR VVTS), hải văn (IOC Sea Level), lưu lượng dòng chảy sông (GloFAS), đặc trưng nhiệt độ đỉnh mây vệ tinh (Himawari-9 IR13) và dự báo số trị (Open-Meteo) dưới dạng Parquet Lakehouse (`nodes`, `edges`), đi kèm script Replay Stream đa tốc độ ($1\times, 10\times, 100\times$) phục vụ kiểm thử chịu tải.
3. **Mô hình AI Giám sát Cảm biến & Dự báo Đa Tầng (Gauge-Anchored AI):**
   - **In-Stream QC:** Bộ lọc Spark Pandas UDF (tối ưu với Spatial k-d tree broadcast) phát hiện trạm hỏng/kẹt phễu theo thời gian thực bằng kiểm chứng chéo không gian và bù khuyết IDW.
   - **Rain Nowcasting & Risk Classification:** Dự báo định lượng lượng mưa và phân lớp xác suất nguy cơ mưa theo từng giờ (+1h, +2h) neo theo đồ thị 32 trạm TP.HCM kết hợp các đặc trưng đối lưu khí quyển (Open-Meteo, Himawari-9). Đánh giá đa tầng qua 3 baselines: **Persistence (Naive) → Spatial IDW + LightGBM → Spatio-Temporal GNN (ST-GNN)**.
4. **Cảnh báo các điểm ngập lũ:** Tích hợp 43 điểm đen ngập úng trọng điểm (trong danh mục 116 vị trí có nguy cơ ngập của Sở Xây dựng TP.HCM, bao gồm 40 tuyến nguy cơ ngập do triều cường sông dâng), tự động kích hoạt cảnh báo tương tác 3 nhân tố: **Mưa dông tại chỗ + Mực nước triều dâng (độ trễ pha truyền sóng sông) + Lưu lượng dòng chảy nền thượng nguồn sông Sài Gòn - Đồng Nai (GloFAS)**.

4 Các Modalities và Nguồn dữ liệu khí tượng - thủy văn TP.HCM

Hệ thống tiếp cận bài toán theo **4 Modalities khí tượng - thủy văn** tập trung vào phạm vi đô thị TP.HCM và vùng đệm thủy văn liên quan (bù đắp cho modality Radar bị khuyết):



Hình 1: Sơ đồ liên kết Modalities và Nguồn Dữ liệu

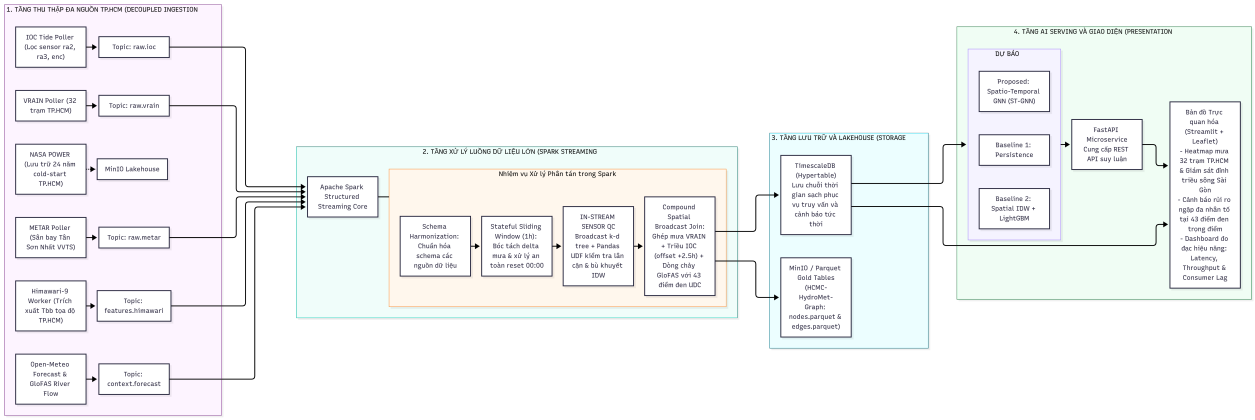
Modality	Tên nguồn	Endpoint / Truy cập	Chu kỳ	Trường dữ liệu chính	Vai trò & Xử lý Veracity
Gauge-based	**VRAIN TP.HCM**	`data.vrain.vn/public/current/56.json`	∼1 giờ	Tọa độ (`lat, lng`), tên trạm, mã trạm (`uuid`), lượng mưa (`sumDepth`), cấp mưa (`level`).	**Ground Truth:** Nhãn mưa thực địa 32 trạm nội ngoại thành TP.HCM (UUID cố định).
Gauge-based	**AWC METAR (NOAA)**	`aviationweather.gov/api/data/metar?ids=VVTS`	30–60 phút	Nhiệt độ (`temp`), điểm sương (`dewp`), khí áp (`altim`), gió (`wdir, wspd`).	**Sân bay Tân Sơn Nhất (VVTS):** Vector gió bề mặt thực tế và áp suất trung tâm TP.HCM.
Hydro-based	**IOC Sea Level (UNESCO)**	`ioc-sealevelmonitoring.org/service.php`	**1 phút**	Mực nước biển (`slevel`), thời gian (`stime`), mã cảm biến (`sensor`).	**Triều cường Vũng Tàu:** Lọc sạch `sensor IN ('ra2', 'ra3', 'enc')`. Áp dụng lệch pha +2.5h truyền vào TP.HCM.
Model-based	**Open-Meteo Forecast**	`api.open-meteo.com/v1/forecast`	1 giờ	Dự báo mưa (`precipitation`), xác suất mưa, gió, khí áp, độ ẩm.	**Feature tương lai:** Phân lớp nguy cơ mưa +1h/+2h theo tọa độ 32 trạm.
Hydro-model	**Open-Meteo GloFAS**	`flood-api.open-meteo.com/v1/flood`	Hàng ngày	Lưu lượng dòng chảy sông Sài Gòn - Đồng Nai (`river_discharge` m^3/s).	**Biến nền thủy văn:** Cảnh báo kết hợp triều dâng gây tràn bờ ven sông/kênh. Broadcast lookup.
Reanalysis	**NASA POWER API**	`power.larc.nasa.gov/api`	Giờ	Nhiệt độ, lượng mưa (`PRECTOTCORR`), gió 10m, độ ẩm, áp suất.	**Backfill Archive:** Giải quyết thiếu hụt dữ liệu huấn luyện Cold-Start ban đầu.
Satellite	**Himawari-9 AHI (NOAA)**	AWS S3 `s3://noaa-himawari9/`	**10 phút**	Kênh hồng ngoại nhiệt độ đỉnh mây (IR Band 13 - 10.4 μm).	**Nhận diện dông nhiệt:** Poller trích xuất T_{bb} tọa độ trạm trước khi stream vào Kafka.
Không gian	**Sở Xây dựng / UDC & SRTM**	43 điểm đen trọng điểm UDC / 116 vị trí Sở XD + DEM 30m	Tĩnh	Tọa độ 43 điểm đen ngập úng TP.HCM (mưa & triều dâng) và độ cao DEM.	Bảng tham chiếu không gian tính ngưỡng thoát nước và cảnh báo ngập đa nhân tố.

Bảng tổng hợp các nguồn dữ liệu đã kiểm chứng thực tế

5 Kiến trúc hệ thống tổng thể (System Architecture)

Các thành phần chính:

- **Tầng 1 (Ingestion Decoupling):** Phân tách thành 5 Kafka topics chuyên biệt để tránh hiện tượng nghẽn hàng đợi (head-of-line blocking). Tập trung ingest 32 trạm VRAIN TP.HCM và sân bay Tân Sơn Nhất. Tiền xử lý dữ liệu vệ tinh Himawari-9 trích xuất chỉ số T_{bb} tại tọa độ các trạm TP.HCM trước khi stream vào Kafka để tối ưu hóa tài nguyên phần cứng.
- **Tầng 2 (Spark Streaming Core):**
  - **AI Workload 1 (In-Stream Sensor QC):** Tối ưu hóa Spark Pandas UDF bằng cách broadcast cây không gian `station_kd_tree`, cho phép tìm kiếm lân cận $\mathcal{O}(\log N)$ cực nhanh giữa các trạm TP.HCM để phát hiện kẹt phễu và bù khuyết IDW.
  - **Cảnh báo Ngập Đa Nhân Tố (Compound Flood Proxy):** Broadcast Join 43 điểm đen trọng điểm (trong danh mục 116 vị trí của Sở Xây dựng TP.HCM, bao gồm 40 tuyến nguy cơ ngập do triều cường ven sông/kênh); kích hoạt cảnh báo nguy cơ ngập cao dựa trên tổ hợp: (1) Mưa tích lũy 1h $\geq$ 25 mm hoặc 3h $\geq$ 40 mm, **KẾT HỢP** (2) Đỉnh triều dâng Vũng Tàu $\geq$ 1.5 m (tính độ lệch pha truyền sóng +2.5 giờ vào sông Sài Gòn), **VÀ** (3) Lưu lượng nền sông thượng nguồn GloFAS ở mức cao làm nghẽn van cống tự động.
- **Tầng 3 (Storage):** TimescaleDB lưu trữ chuỗi thời gian vận hành; MinIO lưu trữ Parquet Lakehouse đa phương thức làm benchmark dataset `HCMC-HydroMet-Graph`.
- **Tầng 4 (AI Serving & Dashboard):**
  - **AI Workload 2 (Rain Nowcasting):** Đánh giá khoa học qua 3 bậc mô hình: Persistence $\rightarrow$ LightGBM $\rightarrow$ ST-GNN.
  - **Streamlit UI:** Bản đồ nhiệt 32 trạm đo thực tế TP.HCM, biểu đồ thủy triều và lưu lượng sông, cảnh báo ngập đa nhân tố tại 43 điểm đen, và giao diện đo đạc benchmark (Latency, Throughput, Kafka Lag) khi chạy Replay Stream $10\times, 100\times$.



Hình 2: Kiến trúc Pipeline Xử lý Dữ liệu Lớn Dạng Luồng (End-to-End Streaming Architecture)